

Segmentasi Provinsi Rawan Krisis Pangan Berdasarkan Pola *Volatilitas* Harga Komoditas Menggunakan *Fuzzy C-Means Clustering*

Muh Yusuf¹

¹*Teknik Informatika, Fakultas Teknik
Universitas Halu Oleo*

Jl. H.E.A. Mokodompit, Kendari, Sulawesi Tenggara 93232

¹*muhyusuf@uho.ac.id*

Corresponding author: muhyusuf@uho.ac.id

Abstrak — Ketahanan pangan merupakan isu strategis di Indonesia mengingat adanya perbedaan kondisi sosial-ekonomi antarprovinsi serta fluktuasi harga pangan yang berpotensi memengaruhi daya beli dan stabilitas konsumsi rumah tangga. Penelitian ini bertujuan melakukan pengelompokan provinsi di Indonesia berdasarkan karakteristik deret waktu harga komoditas pangan guna memetakan risiko ketidakstabilan pangan secara data-driven. Pendekatan yang digunakan adalah metode Fuzzy C-Means (FCM), yang memungkinkan setiap provinsi memiliki derajat keanggotaan pada lebih dari satu kluster sehingga mampu merepresentasikan ketidakpastian dan zona transisi risiko antarwilayah. Data yang digunakan berupa *time series* harga harian sebelas komoditas pangan strategis di 34 provinsi Indonesia, yang diekstraksi menjadi fitur statistik dan temporal meliputi rata-rata harga, volatilitas relatif (*coefficient of variation*), tren, autokorelasi, dan skewness. Penentuan konfigurasi cluster optimal dilakukan berdasarkan kriteria validasi fuzzy, termasuk Fuzzy Partition Coefficient dan Partition Entropy. Hasil analisis menunjukkan adanya heterogenitas risiko ketidakstabilan harga pangan antarprovinsi, yang dapat dikelompokkan ke dalam beberapa tingkat risiko dari rendah hingga tinggi. Temuan ini memberikan perspektif alternatif dalam analisis ketahanan pangan berbasis volatilitas harga dan berpotensi mendukung perumusan kebijakan stabilisasi harga serta mitigasi risiko pangan yang lebih terarah di tingkat regional.

Kata kunci— volatilitas harga pangan, fuzzy C-means, analisis deret waktu, kluster wilayah, ketahanan pangan

Segmentation of Provinces Prone to Food Crises Based on Commodity Price Volatility Patterns Using Fuzzy C-Means Clustering

Abstract — Food security remains a critical issue in Indonesia due to regional socio-economic disparities and food price fluctuations that threaten household purchasing power. This paper presents a data-driven clustering approach to identify provincial vulnerability to food price instability based on commodity price volatility patterns. Daily price time series of eleven strategic food commodities across 34 Indonesian provinces are analyzed and transformed into statistical and temporal features, including mean price, coefficient of variation, trend, autocorrelation, and skewness. Fuzzy C-Means (FCM) clustering is employed to account for uncertainty and gradual transitions between risk levels by allowing provinces to belong to multiple clusters with varying membership degrees. The optimal number of clusters is determined using fuzzy validity indices, namely the Fuzzy Partition Coefficient and Partition Entropy. The results reveal significant heterogeneity in food price instability risk across provinces, which can be categorized into multiple risk levels ranging from low to high. This study provides an alternative perspective on food security analysis based on price volatility and supports more targeted regional policies for food price stabilization and risk mitigation.

Keywords— food price volatility, fuzzy C-means, time series analysis, regional clustering, food security

I. PENDAHULUAN

Ketahanan pangan merupakan salah satu isu strategis nasional yang menjadi prioritas pembangunan Indonesia. Dengan wilayah geografis yang luas mencakup 34 provinsi dan karakteristik geografis kepulauan yang kompleks, Indonesia menghadapi tantangan signifikan dalam menjamin ketersediaan dan aksesibilitas pangan yang merata bagi seluruh masyarakat. Disparitas harga komoditas pangan antar daerah menjadi permasalahan serius yang dapat memicu ketidakstabilan pasokan dan berpotensi menyebabkan krisis pangan regional. Menurut Food and Agriculture Organization (FAO), ketahanan pangan tidak hanya mencakup aspek ketersediaan dan akses, tetapi juga stabilitas pasokan yang tercermin melalui kestabilan harga komoditas pangan dari waktu ke waktu [1].

Stabilitas harga merupakan salah satu pilar fundamental dalam ketahanan pangan karena volatilitas harga yang tinggi dapat mengganggu daya beli masyarakat dan mengancam akses terhadap pangan, terutama bagi kelompok rentan. Penelitian terkini menunjukkan adanya fenomena *spillover effect* volatilitas harga pangan antar provinsi di Indonesia, di mana Pulau Jawa berperan sebagai *transmitter* utama dengan korelasi volatilitas mencapai 0.92 ke Sumatra, 0.91 ke Kalimantan, dan 0.90 ke Papua [2]. Lebih lanjut [3], Studi mengenai volatilitas harga pangan selama periode Covid-19 menemukan adanya hubungan jangka panjang antara fluktuasi harga komoditas strategis seperti cabai, beras, bawang merah, bawang putih, dan ayam dengan volatilitas inflasi regional. Temuan ini menunjukkan bahwa volatilitas harga pangan tidak hanya mencerminkan dinamika pasar lokal, tetapi juga dapat digunakan sebagai indikator awal terhadap potensi gangguan stabilitas ekonomi dan ketahanan pangan di tingkat wilayah.

Dalam konteks metodologi clustering untuk data *time series*, pendekatan berbasis karakteristik statistik telah banyak digunakan untuk menangkap dinamika sistem yang kompleks dan tidak stabil. Penelitian mengenai *autocorrelation-based fuzzy clustering* menunjukkan bahwa penggunaan fungsi autokorelasi sebagai basis pengelompokan memberikan fleksibilitas yang lebih tinggi, karena setiap *time series* tidak ditetapkan secara eksklusif ke satu klaster, melainkan memiliki derajat keanggotaan terhadap beberapa klaster sekaligus. Pendekatan ini sangat relevan untuk data ekonomi dan finansial, termasuk harga pangan, yang cenderung mengandung *noise* tinggi dan perilaku dinamis.

Berbagai penelitian telah dilakukan untuk menganalisis pola harga dan ketahanan pangan di Indonesia menggunakan pendekatan clustering. Salah satu penelitian menerapkan metode *Dynamic Time Warping* (DTW) untuk melakukan *time series clustering* harga beras di 34 provinsi, yang mengelompokkan wilayah berdasarkan kesamaan pola temporal harga [4]. Pendekatan serupa juga diterapkan dalam peramalan harga beras menggunakan hierarchical clustering dengan DTW distance, yang menghasilkan cophenetic coefficient sebesar 0.68 dan mengidentifikasi Kalimantan Tengah sebagai outlier. Studi lain menggunakan kombinasi metode hard clustering seperti K-Means dan K-Medoids serta soft clustering seperti Fuzzy C-Means untuk mengelompokkan 34 provinsi berdasarkan indikator ketahanan pangan dari BPS, dengan hasil menunjukkan bahwa K-Means menghasilkan dua klaster optimal yang memisahkan delapan provinsi rawan pangan dari 26 provinsi tahan pangan [5].

Studi lain yang menerapkan *quantile-based fuzzy clustering* dengan memanfaatkan fitur *conditional variance*, *skewness*, dan *kurtosis* menunjukkan bahwa momen statistik tingkat tinggi dapat menjadi dasar pengelompokan yang lebih robust, khususnya dalam menghadapi keberadaan *outlier* [6]. Selain itu, penelitian mengenai *resilience indicators* pada data longitudinal juga memanfaatkan kombinasi *variance*, *lag-1 autocorrelation*, dan *skewness* sebagai indikator fluktuasi dan ketahanan sistem terhadap gangguan eksternal [7], yang sejalan dengan karakteristik dinamika harga pangan antarwilayah.

Meskipun berbagai studi telah dilakukan untuk menganalisis pola harga dan ketahanan pangan di Indonesia, terdapat beberapa keterbatasan yang dapat diidentifikasi. Pertama, sebagian besar penelitian menggunakan pendekatan DTW distance yang berfokus pada kesamaan bentuk pola *time series* secara keseluruhan, namun kurang mengeksplorasi karakteristik statistik spesifik yang mencerminkan volatilitas, persistensi, dan distribusi harga. Kedua, penelitian clustering ketahanan pangan yang ada lebih banyak menggunakan indikator statis dari BPS, sementara analisis berbasis pola harga sebagai *early warning system* masih terbatas. Ketiga, metode hard clustering seperti K-Means menghasilkan pengelompokan yang rigid dan tidak mampu menangani overlapping characteristics antar provinsi, padahal dalam realitas, banyak provinsi yang memiliki karakteristik pola harga yang berada di zona transisi. Keempat, belum ada penelitian yang secara komprehensif mengintegrasikan lima karakteristik statistik *time series* (mean, coefficient of variation, autocorrelation, trend, dan skewness) sebagai feature untuk segmentasi provinsi berdasarkan pola volatilitas harga komoditas pangan strategis.

Untuk mengatasi keterbatasan tersebut, penelitian ini mengusulkan pendekatan berbasis algoritma *Fuzzy C-Means* (FCM) clustering sebagai kontribusi utama. FCM memberikan derajat keanggotaan (*membership degree*) yang fleksibel, sehingga setiap provinsi dapat memiliki tingkat keanggotaan pada lebih dari satu klaster secara simultan. Karakteristik ini sangat sesuai untuk data harga komoditas pangan yang bersifat dinamis dan fluktuatif, di mana batas antar kelompok wilayah tidak selalu tegas.


Selain itu, FCM relatif lebih robust dalam menghadapi ketidakpastian data dan mampu merepresentasikan sifat *fuzzy* dari fenomena ekonomi, di mana suatu wilayah dapat berada dalam kondisi transisi antara stabil dan rawan. Dengan mengintegrasikan lima fitur statistik *time series*—yaitu *mean*, *coefficient of variation*, *autocorrelation*, *trend*, dan *skewness*—penelitian ini memberikan kerangka analisis yang lebih komprehensif untuk mengkarakterisasi dinamika volatilitas harga komoditas

pangan antarprovinsi, serta mendukung identifikasi risiko ketahanan pangan secara lebih informatif.

Penelitian ini bertujuan untuk melakukan segmentasi 34 provinsi di Indonesia berdasarkan pola volatilitas harga 10 komoditas pangan strategis menggunakan algoritma Fuzzy C-Means Clustering. Analisis dilakukan untuk mengidentifikasi karakteristik cluster yang terbentuk dan menentukan provinsi-provinsi yang memiliki pola volatilitas harga tinggi yang mengindikasikan kerentanan terhadap krisis pangan. Hasil penelitian menunjukkan terbentuknya dua cluster optimal yang dapat digunakan sebagai dasar sistem peringatan dini (early warning system) bagi pengambil kebijakan. Kontribusi penelitian ini meliputi: (1) penyediaan metode segmentasi wilayah berbasis pola volatilitas harga yang lebih fleksibel dan robust melalui pendekatan fuzzy clustering; (2) identifikasi provinsi-provinsi prioritas yang memerlukan intervensi kebijakan stabilisasi harga seperti subsidi, operasi pasar, atau penguatan buffer stock; (3) pengembangan framework analisis yang mengintegrasikan multiple time series features untuk early warning system krisis pangan; dan (4) rekomendasi kebijakan yang berbasis evidence untuk penguatan ketahanan pangan regional di Indonesia.

II. METODE PENELITIAN

Penelitian ini dilakukan melalui beberapa tahapan sistematis untuk melakukan segmentasi provinsi berdasarkan pola volatilitas harga komoditas pangan menggunakan algoritma Fuzzy C-Means Clustering. Alur penelitian secara keseluruhan ditunjukkan pada Gambar 1. Tahapan penelitian dimulai dari pengumpulan data time series harga komoditas pangan dari 34 provinsi di Indonesia, dilanjutkan dengan preprocessing data untuk memastikan kualitas dan konsistensi data. Selanjutnya dilakukan ekstraksi fitur statistik time series yang mencakup mean, coefficient of variation, autocorrelation, trend, dan skewness untuk merepresentasikan karakteristik pola harga di setiap provinsi. Fitur-fitur tersebut kemudian menjadi input untuk algoritma Fuzzy C-Means Clustering yang menghasilkan segmentasi provinsi ke dalam beberapa cluster. Jumlah cluster optimal ditentukan melalui evaluasi menggunakan beberapa indeks validasi cluster. Terakhir, dilakukan karakterisasi dan interpretasi setiap cluster untuk mengidentifikasi provinsi-provinsi yang rawan krisis pangan berdasarkan pola volatilitas harga komoditas. Penjelasan detail dari setiap tahapan penelitian diuraikan pada subsection berikut.



Gambar 1: Alur Penelitian Segmentasi Provinsi Rawan Krisis Pangan

A. Data dan Sumber Data

Penelitian ini menggunakan data time series harga komoditas pangan yang bersumber dari Kaggle [8]. Dataset terdiri dari 13 komoditas pangan strategis dengan periode observasi dari Januari 2022 hingga September 2024. Setiap dataset merepresentasikan harga satu komoditas untuk 34 provinsi di Indonesia dalam format mingguan. Total observasi mencakup $34 \text{ provinsi} \times 143 \text{ minggu} \times 13 \text{ komoditas}$, menghasilkan 63.206 data point harga komoditas pangan.

Tiga belas komoditas pangan yang dianalisis dalam penelitian ini meliputi:

1. Bawang merah
2. Bawang putih bonggol

3. Beras medium
4. Beras premium
5. Cabai merah keriting
6. Cabai rawit merah
7. Daging ayam ras
8. Daging sapi murni
9. Gula konsumsi
10. Minyak goreng curah
11. Minyak goreng kemasan
12. Telur ayam ras
13. Tepung terigu curah

Format data yang digunakan adalah *cross-sectional time series* (panel data), di mana setiap dataset komoditas memiliki struktur dengan kolom representasi provinsi dan baris representasi periode waktu. Contoh struktur data untuk komoditas bawang merah ditunjukkan pada Tabel 1.

TABEL 1: CONTOH STRUKTUR DATA HARGA KOMODITAS BAWANG MERAH (DALAM RUPIAH)

Date	Aceh	Bali	Banten	Bengkulu	...
2022-01-01	28.970	20.870	26.890	26.650	...
2022-01-02	29.900	20.710	25.600	26.950	...
2022-01-03	28.970	20.510	26.390	27.290	...
⋮	⋮	⋮	⋮	⋮	⋮

Setiap baris pada dataset merepresentasikan harga komoditas pada tanggal tertentu, sedangkan setiap kolom merepresentasikan provinsi di Indonesia. Data harga dinyatakan dalam satuan Rupiah per kilogram untuk seluruh komoditas.

B. Preprocessing

Exploratory data analysis (EDA) awal terhadap 13 komoditas pangan menunjukkan adanya missing value dengan proporsi yang berbeda-beda, untuk memastikan kualitas dan reliabilitas analisis clustering, dilakukan evaluasi sistematis terhadap pola missing value setiap komoditas.

1) *Tahap 1: Identifikasi komoditas dengan Missing Value Ekstrem:* Analisis missing value per komoditas menunjukkan bahwa dua komoditas memiliki proporsi missing value yang sangat tinggi:


- **Cabai Rawit Merah:** 80.78% baris mengandung missing value, dengan Provinsi Aceh mencatat 77.89% missing dari total observasi
- **Minyak Goreng Curah:** 48.01% baris mengandung missing value, dengan beberapa provinsi seperti Maluku Utara (34.26%), Kalimantan Utara (29.68%), dan Papua (19.62%) memiliki missing value substansial

Kedua komoditas ini di-drop dari analisis dengan pertimbangan:

1. Proporsi missing value yang sangat tinggi (>40%) dapat menghasilkan bias signifikan dalam imputasi
2. Missing value yang ekstrem pada provinsi-provinsi tertentu mengindikasikan potensi systematic data collection issues
3. Imputasi pada data dengan missing ekstrem akan lebih banyak menghasilkan data sintetis dibanding data observasi aktual, yang bertentangan dengan prinsip analisis berbasis evidence

Setelah penghapusan dua komoditas tersebut, tersisa 11 komoditas untuk analisis lebih lanjut.

2) *Tahap 2: Analisis Pola Missing Value:* untuk 11 komoditas tersisa dilakukan analisis pola missing value menggunakan heatmap untuk mengidentifikasi temporal pattern dari missing data gambar2,dapat terlihat jika komoditas minyak goreng kemasan memiliki korelasi yang tidak cukup kuat sementara 10 komoditas lain justru identik dengan nilai ≈ 1




Gambar 2: Heatmap korelasi missing antar komoditas

lebih lanjut pada gambar3 terlihat bahwa komoditas minyak goreng kemasan memiliki *unique missing value* dimana 10 komoditas lain hari missing data hanya 46 hari sementara komoditas minyak goreng kemasan justru sampai 93 hari, ini juga semakin menegaskan bahwa tipe missing pada dataset adalah *Missing Completely at Random* (MCAR), sementara itu pada komoditas minyak goreng dengan missing *unique* maka kemungkinan missing adalah *Missing at Random* (MAR) atau *Missing Not at Random* (MNAR).

Mengingat perbedaan mekanisme missing dapat mengintroduksi bias dalam analisis clustering dan mengurangi homogenitas karakteristik data, komoditas dengan pola missing unik ini di-drop dari analisis. Keputusan ini juga didukung oleh prinsip bahwa mixing data dengan mekanisme missing yang berbeda dapat menghasilkan estimasi parameter yang bias dan inference yang tidak valid.

Pada data harga 10 komoditas terpilih, ditemukan periode dengan missing value yang terjadi secara serentak pada rentang tanggal 10 Juni 2022 hingga 19 Juni 2022. Periode ini selanjutnya disebut sebagai *black period*, karena seluruh komoditas tidak memiliki observasi harga pada rentang waktu tersebut.

Sebagai tindak lanjut, seluruh observasi pada rentang *black period* tersebut dihapus dari dataset dengan tujuan untuk menghindari distorsi pada proses ekstraksi fitur statistik, khususnya pada perhitungan autokorelasi, tren jangka panjang, dan ukuran volatilitas. Keberadaan periode tanpa observasi secara kolektif berpotensi mengganggu kontinuitas deret waktu dan menghasilkan estimasi parameter yang tidak stabil, sehingga penghapusan periode ini dilakukan untuk menjaga integritas analisis dan konsistensi pola temporal data.



Gambar 3: Heatmap overlap missing day

Selanjutnya setelah mengatasi missing value, dibutuhkan juga pendeteksian data anomali atau *outliers* dan metode untuk menangani *outliers*. Outlier pada data harga komoditas dapat berasal dari noise atau genuine extreme events seperti lonjakan harga akibat gangguan pasokan. Untuk menangani outlier tanpa menghilangkan informasi penting tentang volatilitas, digunakan pendekatan adaptive IQR-based outlier detection dengan strategi yang disesuaikan untuk setiap komoditas.

3) *tahap1: Deteksi Outliers*: Penanganan outlier pada data harga komoditas dilakukan secara adaptif berdasarkan tingkat volatilitas relatif yang diukur menggunakan coefficient of variation (CV). Pendekatan ini digunakan untuk menyesuaikan sensitivitas deteksi outlier terhadap karakteristik fluktuasi masing-masing komoditas, sehingga lonjakan harga yang bersifat struktural tidak keliru diidentifikasi sebagai noise.

Tabel 2 merangkum nilai CV, ambang deteksi outlier berbasis interquartile range (IQR), serta batas interpolasi yang digunakan untuk setiap komoditas. Komoditas dengan tingkat volatilitas tinggi diberikan ambang IQR yang lebih longgar untuk menjaga pola lonjakan harga alami, sementara komoditas yang relatif stabil diperlakukan dengan kriteria yang lebih ketat. Pendekatan ini memungkinkan proses pembersihan data yang kontekstual tanpa menghilangkan informasi volatilitas yang relevan untuk analisis lanjutan.

TABEL 2: STRATEGI PENANGANAN OUTLIER ADAPTIF BERBASIS COEFFICIENT OF VARIATION (CV) PADA MASING-MASING KOMODITAS PANGAN

Komoditas	CV	CV_std	Outliers (3×)	Recommended IQR
Cabai Merah	0.33	0.082	0.0%	6×
Bawang Merah	0.27	0.041	0.2%	5×
Bawang Putih	0.22	0.029	0.0%	5×
Telur Ayam	0.13	0.014	0.22%	4×
Daging Ayam	0.16	0.022	0.0%	4.5×
Beras Premium	0.13	0.022	0.0%	4×
Beras Medium	0.13	0.025	0.0%	4×
Gula	0.11	0.008	0.0%	4×
Tepung Terigu	0.11	0.015	0.003%	4×
Daging Sapi	0.09	0.010	0.0%	4×

4) *Tahap2: Membersihkan outliers dan melakukan imputasi:* setelah mengidentifikasi tipe outliers pada tiap komoditas, maka selanjutnya adalah menghapus outliers dan melakukan imputasi pada data tersisa, pada tabel 3 setelah melakukan cleaning pada outliers dan melakukan imputasi dengan metode interpolasi linear sisa missing value pada sebagian besar komoditas sudah tidak ada sementara itu untuk komoditas Cabai merah masih tersisa 140(15%) data dan pada komoditas daging sapi 459 data(47%), komoditas tersebut masih akan dipertahankan karena data valid masih diatas threshold minimal yaitu 50%.

TABEL 3: JUMLAH MISSING VALUE SETELAH PROSES PEMBERSIHAN PADA MASING-MASING KOMODITAS

Komoditas	Missing After
Bawang Merah	0
Beras Medium	0
Beras Premium	0
Telur Ayam	0
Gula	0
Bawang Putih	0
Cabai Merah	140
Daging Ayam Ras	0
Daging Sapi	459
Tepung Terigu	0

C. Feature Extraction

Algoritma *Fuzzy C-Means* membutuhkan representasi numerik dari pola harga *time series* untuk melakukan proses clustering. Pada penelitian ini digunakan lima fitur statistik utama yang diekstraksi dari data harga komoditas untuk merepresentasikan karakteristik pola harga antar provinsi.

1. Rata-rata (Mean)

Rata-rata digunakan untuk merepresentasikan tingkat harga umum suatu komoditas pada suatu provinsi. Secara matematis, rata-rata harga didefinisikan sebagai:

$$\bar{X}_{ij} = \frac{1}{T} \sum_{t=1}^T X_{ijt} \quad (1)$$

di mana X_{ijt} menyatakan harga komoditas ke- j di provinsi ke- i pada waktu ke- t , dan T adalah jumlah total observasi waktu. Nilai rata-rata ini mencerminkan level harga umum yang berhubungan dengan biaya akses pangan di setiap wilayah.

2. Coefficient of Variation (CV)

Coefficient of Variation (CV) merupakan ukuran statistik yang menggambarkan tingkat volatilitas relatif suatu data terhadap nilai rata-ratanya. Berbeda dengan simpangan baku absolut, CV bersifat bebas skala sehingga memungkinkan perbandingan tingkat volatilitas antar komoditas yang memiliki level harga berbeda. Secara matematis, CV didefinisikan sebagai:

$$CV_{ij} = \frac{\sigma_{ij}}{\bar{X}_{ij}} \times 100\% \quad (2)$$

dengan σ_{ij} menyatakan simpangan baku harga komoditas ke- j di provinsi ke- i , yang dihitung sebagai:

$$\sigma_{ij} = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (X_{ijt} - \bar{X}_{ij})^2} \quad (3)$$

di mana X_{ijt} merupakan harga komoditas ke- j di provinsi ke- i pada waktu ke- t , dan T adalah jumlah total observasi waktu. Nilai CV yang lebih tinggi menunjukkan tingkat fluktuasi harga yang lebih besar relatif terhadap rata-ratanya, sehingga mencerminkan tingkat ketidakstabilan harga yang berpotensi berdampak pada risiko ketahanan pangan di suatu wilayah. Nilai CV yang lebih tinggi menunjukkan tingkat volatilitas harga yang lebih besar relatif terhadap nilai rata-ratanya, sementara nilai CV yang rendah mencerminkan harga yang lebih stabil.

3. Autocorrelation(lag - 1)

Autocorrelation adalah ukuran seberapa kuat suatu variabel berkorelasi dengan dirinya sendiri di waktu atau jarak yang berbeda, autocorrelation mengukur hubungan nilai deret waktu sekarang dengan nilai deret waktu yang sama pada beberapa langkah sebelumnya (lag), secara matematis autocorrelation didefinisikan sebagai berikut:

$$\rho_{ij}(1) = \frac{\sum_{t=2}^T (X_{ijt} - \bar{X}_{ij})(X_{ij(t-1)} - \bar{X}_{ij})}{\sum_{t=1}^T (X_{ijt} - \bar{X}_{ij})^2} \quad (4)$$

formula diatas pada dasarnya merupakan bentuk khusus koefisien korelasi pearson antara X_{ijt} pada waktu t dan nilai waktu sebelumnya $X_{ij(t-1)}$ (lag - 1) setelah dikoreksi dengan nilai rata-ratanya $\bar{X}_{ij}$ lalu dibagi dengan deviasi dari rata-rata waktu t , nilai *Autocorrelation* berada pada rentang $[-1, 1]$, di mana nilai yang mendekati 1 menunjukkan persistensi harga yang kuat, sedangkan nilai mendekati 0 menunjukkan pola harga yang lebih acak dan sulit diprediksi. *Autocorrelation* ini menggambarkan tingkat persistensi temporal harga, yaitu sejauh mana pergerakan harga pada periode sebelumnya memengaruhi harga pada periode saat ini.

4. Trend

Trend adalah metode untuk mengidentifikasi kecenderungan atau arah perkembangan data dalam jangka waktu panjang, secara matematis *Trend* didefinisikan sebagai berikut:

$$X_{ijt} = \alpha_{ij} + \beta_{ij} \cdot t + \epsilon_{ijt} \quad (5)$$

dimana X_{ijt} adalah posisi pada unit i , komoditas j dan waktu t α_{ij} adalah intercept atau nilai saat $t = 0$ dan ϵ_{ijt} adalah error yang menangkap variasi acak, dan β_{ij} adalah:

$$\beta_{ij} = \frac{T \sum_{t=1}^T t \cdot X_{ijt} - \sum_{t=1}^T t \sum_{t=1}^T X_{ijt}}{T \sum_{t=1}^T t^2 - \left(\sum_{t=1}^T t \right)^2} \quad (6)$$

Merepresentasikan komponen kecenderungan jangka panjang dalam deret waktu harga (naik, turun, atau stabil).

5. Skewness

Skewness adalah ukuran yang menyatakan seberapa tidak simetris (miring) terhadap suatu data, *Skewness* didefinisikan sebagai berikut:

$$Skew_{ij} = \frac{T}{(T-1)(T-2)} \sum_{t=1}^T \left(\frac{X_{ijt} - \bar{X}_{ij}}{\sigma_{ij}} \right)^3 \quad (7)$$

Nilai *Skewness* bernilai nol pada distribusi yang simetris, bernilai positif pada distribusi yang condong ke kanan (right-skewed), dan bernilai negatif pada distribusi yang condong ke kiri (left-skewed). *Skewness* yang tinggi mengindikasikan potensi kejadian harga ekstrem, khususnya lonjakan harga yang jarang terjadi namun signifikan.

Berdasarkan proses *feature extraction* yang dilakukan, setiap komoditas pada masing-masing provinsi direpresentasikan oleh lima fitur statistik utama, yaitu rata-rata harga (mean), coefficient of variation (CV), autokorelasi lag-1, tren jangka panjang, dan skewness distribusi harga. Kelima fitur tersebut secara bersama-sama merepresentasikan level harga umum, tingkat volatilitas relatif, persistensi temporal, kecenderungan perubahan jangka panjang, serta potensi kejadian harga ekstrem. Kombinasi fitur ini dirancang untuk menangkap karakteristik dinamika harga yang relevan dalam mengidentifikasi perbedaan tingkat risiko kerawanan pangan antar wilayah. Selanjutnya, matriks fitur yang dihasilkan digunakan sebagai masukan dalam proses clustering.

Setelah seluruh fitur statistik diekstraksi, matriks fitur yang dihasilkan dinormalisasi menggunakan metode Z-score. Normalisasi ini diterapkan untuk menyamakan skala antar fitur yang memiliki rentang nilai dan sebaran yang berbeda. Proses

normalisasi dilakukan pada ruang fitur, bukan pada data deret waktu harga secara langsung, sehingga interpretasi statistik dari setiap fitur tetap terjaga. Normalisasi ini diperlukan sebelum proses clustering karena algoritma *Fuzzy C-Means* berbasis jarak Euclidean yang sensitif terhadap perbedaan skala variabel.

D. Algoritma Fuzzy C-Means Clustering

Fuzzy C-Means (FCM) merupakan salah satu algoritma clustering yang mengadopsi konsep *fuzzy logic*, yaitu pendekatan matematis yang memungkinkan nilai keanggotaan tidak bersifat biner (*true* atau *false*), melainkan berada pada rentang kontinu antara 0 dan 1. Dalam konteks fuzzy clustering, setiap titik data tidak dipaksa untuk menjadi anggota tunggal dari satu cluster, tetapi dapat memiliki derajat keanggotaan pada beberapa cluster secara bersamaan.

Pendekatan ini sangat sesuai untuk data dengan karakteristik yang saling tumpang tindih, ukuran cluster yang tidak seragam, serta data yang mengandung noise dan outlier, sehingga memberikan fleksibilitas yang lebih tinggi dibandingkan metode hard clustering [9].

Algoritma Fuzzy C-Means bekerja dengan meminimalkan fungsi objektif yang mengukur jarak antara data dan pusat cluster dengan mempertimbangkan derajat keanggotaan fuzzy. Fungsi objektif FCM dirumuskan sebagai berikut:

$$J_m = \sum_{i=1}^N \sum_{k=1}^c u_{ik}^m \|x_i - c_k\|^2 \quad (8)$$

di mana x_i merupakan vektor fitur dari data ke- i , v_k adalah pusat cluster ke- k , u_{ik} menyatakan derajat keanggotaan data ke- i terhadap cluster ke- k , $m > 1$ adalah parameter *fuzziness* yang mengontrol tingkat ketidakjelasan partisi, N adalah jumlah total data, dan c adalah jumlah cluster.

Nilai derajat keanggotaan (*membership*) sendiri diperbarui pada setiap iterasi berdasarkan jarak relatif data terhadap seluruh pusat cluster, dengan formula sebagai berikut:

$$u_{ij} = \frac{1}{\sum_{k=1}^C \left(\frac{\|x_i - c_j\|}{\|x_i - c_k\|} \right)^{\frac{2}{m-1}}} \quad (9)$$

Pusat cluster kemudian diperbarui menggunakan rata-rata berbobot derajat keanggotaan:

$$c_j = \frac{\sum_{i=1}^N u_{ij}^m x_i}{\sum_{i=1}^N u_{ij}^m} \quad (10)$$

Proses iterasi dilakukan secara berulang dengan memperbarui nilai keanggotaan dan pusat cluster hingga fungsi objektif J_m mencapai kondisi konvergen atau jumlah iterasi maksimum terpenuhi. Pseudocode algoritma Fuzzy C-Means ditunjukkan pada Algoritma 1.

Algorithm 1 Fuzzy C-Means Clustering

- 1: **Input:** Data $X = \{x_1, \dots, x_N\}$, jumlah cluster c , fuzziness $m > 1$, toleransi ε , iterasi maksimum $maxIter$
 - 2: **Output:** Matriks keanggotaan U , pusat cluster C
 - 3: Inisialisasi matriks keanggotaan U secara acak
 - 4: $iter \leftarrow 0$
 - 5: **repeat**
 - 6: $iter \leftarrow iter + 1$
 - 7: Perbarui pusat cluster c_j menggunakan persamaan (10)
 - 8: Simpan $U_{old} \leftarrow U$
 - 9: Perbarui matriks keanggotaan U menggunakan persamaan (9)
 - 10: **until** $\|U - U_{old}\| < \varepsilon$ **atau** $iter \geq maxIter$
 - 11: **return** U, C
-

Fuzzy C-Means merupakan metode *unsupervised learning*, sehingga evaluasi hasil clustering dilakukan menggunakan metrik validasi internal yang mengukur tingkat kekompakan dan keterpisahan cluster. Pada penelitian ini digunakan beberapa metrik validasi, antara lain Davies–Bouldin Index, Fuzzy Partition Coefficient (FPC), Partition Entropy (PE).

Pemilihan algoritma Fuzzy C-Means pada penelitian ini didasarkan pada karakteristik data yang menunjukkan adanya tumpang tindih antar kelompok, keberadaan noise dan outlier, serta distribusi fitur yang tidak seragam. Studi sebelumnya

menunjukkan bahwa Fuzzy C-Means (FCM) mampu mengelompokkan data dengan ukuran cluster yang tidak seimbang, mengandung noise, dan memiliki distribusi massa yang tidak uniform secara lebih efektif dibandingkan algoritma clustering lainnya [9]. Karakteristik tersebut sejalan dengan data penelitian ini yang direpresentasikan dalam bentuk fitur statistik hasil ekstraksi dari deret waktu harga, sehingga pendekatan clustering berbasis fuzzy dinilai lebih sesuai untuk menangkap pola transisi dan ketidakpastian antar cluster.

E. Pemilihan Jumlah Cluster Optimal

Penentuan jumlah cluster optimal dapat dilakukan melalui dua pendekatan utama. Pendekatan pertama menggunakan indeks validasi tertentu yang secara langsung mengestimasi kualitas partisi, seperti Xie–Beni Index. Pendekatan kedua dilakukan dengan mengevaluasi performa hasil clustering pada berbagai jumlah cluster dengan menjalankan algoritma Fuzzy C-Means secara berulang pada rentang nilai tertentu.

Pada penelitian ini digunakan pendekatan kedua, yaitu dengan menguji jumlah cluster c pada rentang 2 hingga 10. Untuk setiap nilai c , algoritma Fuzzy C-Means dijalankan dan hasil clustering dievaluasi menggunakan metrik validasi internal. Jumlah cluster optimal kemudian ditentukan berdasarkan nilai metrik evaluasi yang menunjukkan performa terbaik. Pendekatan ini dipilih karena memberikan fleksibilitas dalam mengamati stabilitas dan kualitas struktur cluster pada berbagai skenario jumlah cluster.


Tabel 4 menyajikan ringkasan hasil evaluasi Fuzzy C-Means untuk beberapa variasi jumlah cluster. Nilai lengkap untuk seluruh rentang jumlah cluster $c = 2$ hingga $c = 10$ digunakan dalam proses evaluasi, namun hanya sebagian nilai ditampilkan pada tabel untuk kejelasan penyajian.

TABEL 4: RINGKASAN HASIL FCM UNTUK BERBAGAI NILAI c

c	DBI	Partition Coef.	Partition Entropy	Cluster sizes
2	1.6812	0.5615	0.6289	[12, 22]
3	2.1182	0.3741	1.0298	[9, 17, 8]
4	2.0632	0.2806	1.3162	[7, 0, 10, 17]
...				

Berdasarkan hasil evaluasi pada Tabel 4, konfigurasi dengan jumlah cluster $c = 2$ memberikan performa terbaik dibandingkan konfigurasi lainnya. Hal ini ditunjukkan oleh nilai Davies–Bouldin Index (DBI) yang paling rendah sebesar 1.6812, nilai Partition Coefficient (PC) tertinggi sebesar 0.5615, serta nilai Partition Entropy (PE) terendah sebesar 0.6289.

Tren perubahan nilai metrik evaluasi terhadap variasi jumlah cluster ditunjukkan pada Gambar 4. Terlihat bahwa peningkatan jumlah cluster tidak diikuti oleh perbaikan kualitas clustering secara konsisten, yang ditandai dengan meningkatnya nilai DBI dan menurunnya nilai Partition Coefficient. Oleh karena itu, jumlah cluster $c = 2$ dipilih sebagai konfigurasi optimal dan digunakan pada tahap analisis selanjutnya.



Gambar 4: Perubahan nilai Davies–Bouldin Index dan Partition Coefficient terhadap variasi jumlah cluster

F. Interpretasi Cluster

Setelah diperoleh jumlah cluster optimal, interpretasi dilakukan menggunakan pendekatan *Per-Cluster Aggregated Statistics* (PCAS). Setiap provinsi diasosiasikan ke cluster dengan derajat keanggotaan tertinggi (*hard assignment*), kemudian nilai agregat fitur untuk setiap cluster dihitung sebagai berikut:

$$\bar{X}_c = \frac{1}{N_c} \sum_{i \in C_c} \left(\frac{1}{K} \sum_{k=1}^K X_{i,k} \right) \quad (11)$$

Selanjutnya, untuk setiap cluster dihitung statistik deskriptif berupa nilai rata-rata dan standar deviasi ($\text{mean} \pm \text{std}$) dari masing-masing fitur guna membandingkan karakteristik relatif antar cluster.

G. Klasifikasi Risiko Kerawanan Pangan

Tahap selanjutnya adalah melakukan klasifikasi tingkat kerawanan pangan pada setiap provinsi berdasarkan karakteristik cluster yang diperoleh. Klasifikasi risiko ini tidak merupakan keluaran langsung dari algoritma Fuzzy C-Means, melainkan diturunkan melalui formulasi skor risiko berbasis fitur utama hasil clustering.

Indikator utama yang digunakan dalam penentuan risiko adalah *Coefficient of Variation* (CV) sebagai representasi volatilitas harga. Sementara itu, fitur *trend* dan *skewness* digunakan sebagai faktor koreksi untuk menangkap dinamika arah perubahan harga dan potensi kejadian ekstrem. Skor risiko untuk setiap cluster didefinisikan sebagai berikut:

$$\text{RiskScore}_c = \overline{CV}_c + \alpha \overline{\text{Trend}}_c + \beta \overline{\text{Skew}}_c \quad (12)$$

dengan $\overline{CV}_c$, $\overline{\text{Trend}}_c$, dan $\overline{\text{Skew}}_c$ masing-masing menyatakan nilai rata-rata fitur pada cluster ke- c , serta parameter pembobot $\alpha = 100$ dan $\beta = 0.1$ yang digunakan untuk menyesuaikan skala kontribusi masing-masing fitur.

III. HASIL DAN PEMBAHASAN

A. Hasil Clustering Fuzzy C-Means

Berdasarkan hasil konfigurasi optimal, proses clustering menggunakan parameter $c = 2$ dan $m = 2$ mencapai kondisi konvergen setelah 19 kali iterasi. Nilai fungsi objektif akhir dengan sebesar 842.021318 dengan nilai Partition Coefficient 0.5608, ringkasan hasil clustering lebih lengkap pada tabel 5.

TABEL 5: RINGKASAN HASIL FUZZY C-MEANS CLUSTERING ($c = 2, m = 2$)

Metrik	Nilai
Iterasi Konvergensi	19
Objective Function (J_m)	842.0213
Partition Coefficient (FPC)	0.5608
Perubahan J_m (Δ)	-199.3514
Ukuran Cluster	[12, 22]
Maximum Membership	0.8281

Nilai Partition Coefficient sebesar 0.5608 menunjukkan adanya tingkat overlap antar cluster yang bersifat moderat, yang mengindikasikan bahwa sebagian provinsi memiliki karakteristik yang tidak sepenuhnya terpisah secara tegas. Dengan konfigurasi jumlah cluster yang telah ditetapkan, distribusi provinsi berdasarkan hasil clustering Fuzzy C-Means disajikan pada Tabel 6.

Hasil clustering yang diperoleh selanjutnya dianalisis untuk mengidentifikasi karakteristik dan perbedaan pola antar cluster.

B. Karakteristik dan Interpretasi Cluster

Metode yang digunakan untuk mengetahui karakteristik tiap cluster dengan menggunakan metode *Per-Cluster Aggregated Statistics* (PCAS) dengan hard assignment dari membership matrix U , kemudian statistik deskriptif ($\text{mean} \pm \text{std}$) dihitung per feature type dengan agregasi lintas komoditas. tabel hasil karakteristik cluster disajikan di tabel 7. komoditas:

TABEL 6: KOMPOSISI PROVINSI BERDASARKAN HASIL CLUSTERING FUZZY C-MEANS ($c = 2$)

Cluster 0 (12 provinsi)	Cluster 1 (22 provinsi)
Kalimantan Barat	Aceh
Kalimantan Selatan	Bali
Kalimantan Tengah	Banten
Kalimantan Timur	Bengkulu
Kalimantan Utara	DI Yogyakarta
Kepulauan Riau	DKI Jakarta
Maluku	Gorontalo
Maluku Utara	Jambi
Nusa Tenggara Timur	Jawa Barat
Papua	Jawa Tengah
Papua Barat	Jawa Timur
Sulawesi Tenggara	Kepulauan Bangka Belitung
	Lampung
	Nusa Tenggara Barat
	Riau
	Sulawesi Barat
	Sulawesi Selatan
	Sulawesi Tengah
	Sulawesi Utara
	Sumatera Barat
	Sumatera Selatan
	Sumatera Utara

TABEL 7: KARAKTERISTIK FEATURE TYPES FUZZY C-MEANS ($c = 2$)

Feature	Cluster 0	Cluster 1	Diff (%)	Keterangan
Mean	41,319 $\pm$ 4,815	35,823 $\pm$ 2,892	+15.3%	Nilai rata-rata C0 lebih besar
CV	0.098 $\pm$ 0.023	0.131 $\pm$ 0.020	-25.3%	Variabilitas C1 lebih tinggi
Trend	0.0002 $\pm$ 0.0001	0.0002 $\pm$ 0.0001	-11.3%	Perbedaan relatif kecil
Autocorr	0.945 $\pm$ 0.049	0.982 $\pm$ 0.014	-3.8%	Pola temporal serupa
Skewness	0.158 $\pm$ 0.387	0.180 $\pm$ 0.318	-12.5%	Distribusi relatif mirip

Berdasarkan Tabel 7, cluster 0 memiliki nilai rata-rata harga (*mean*) yang lebih tinggi dibandingkan cluster 1, dengan selisih sekitar 15.3%. Sebaliknya, nilai *Coefficient of Variation* (CV) pada cluster 1 lebih tinggi sekitar 25.3%, yang menunjukkan bahwa cluster dengan harga relatif lebih rendah cenderung memiliki volatilitas yang lebih tinggi.

Untuk fitur *trend*, *autocorrelation*, dan *skewness*, perbedaan antar cluster relatif kecil, masing-masing sekitar 11.3%, 3.8%, dan 12.5%. Hal ini mengindikasikan bahwa perbedaan utama antar cluster lebih didominasi oleh tingkat harga dan volatilitas, sementara karakteristik dinamika temporal relatif serupa.

Perbedaan karakteristik ini selanjutnya digunakan sebagai dasar untuk mengkaji tingkat kejelasan partisi cluster dan pola keanggotaan fuzzy pada masing-masing provinsi.

C. Analisis Derajat Keanggotaan Fuzzy

Selanjutnya, analisis distribusi derajat keanggotaan (*membership*) dilakukan untuk mengevaluasi seberapa kuat asosiasi setiap provinsi terhadap cluster tertentu. Tabel 8 menyajikan ringkasan distribusi derajat keanggotaan fuzzy untuk masing-masing cluster.


TABEL 8: DISTRIBUSI DERAJAT KEANGGOTAAN FUZZY PER CLUSTER

Kategori Membership	Rentang u_{ik}	Cluster 0	Cluster 1
Dominan	$u_{ik} \geq 0.8$	0	2
Menengah	$0.6 \leq u_{ik} < 0.8$	6	14
Ambigu	$0.4 \leq u_{ik} < 0.6$	6	6

Hasil analisis menunjukkan bahwa hanya terdapat dua provinsi yang memiliki derajat keanggotaan dominan terhadap cluster tertentu. Sebaliknya, kategori keanggotaan menengah mendominasi hasil clustering dengan total 20 provinsi pada kedua cluster. Selain itu, masih terdapat 12 provinsi yang berada pada kategori keanggotaan ambigu, yang mengindikasikan

adanya overlap karakteristik antar cluster.

lebih lanjut pada histogram pada gambar 5, menunjukkan distribusi derajat keanggotaan fuzzy untuk masing-masing cluster. Terlihat bahwa distribusi keanggotaan pada cluster 0 cenderung berada pada rentang menengah, dengan nilai rata-rata sekitar 0.43, yang mengindikasikan adanya sejumlah provinsi dengan keanggotaan ambigu. Sebaliknya, cluster 1 menunjukkan nilai keanggotaan yang relatif lebih tinggi dengan rata-rata sekitar 0.57, yang mencerminkan partisi yang lebih jelas dibandingkan cluster 0. Sementara itu nilai mean *Adjusted Rand Index* (ARI) bernilai 0.6647 dengan 50 bootstrap umum mengindikasikan bahwa solusi dua cluster bersifat cukup stabil dan dapat dilakukan analisis lanjutan.



Gambar 5: Distribusi Derajat

D. Klasifikasi Risiko

Setelah menganalisis derajat keanggotaan dan karakteristik masing-masing cluster, tahap selanjutnya adalah melakukan klasifikasi risiko kerawanan pangan untuk menentukan tingkat kerentanan setiap cluster terhadap ketidakstabilan pasokan pangan. Klasifikasi ini dilakukan berdasarkan perhitungan risk score menggunakan Persamaan 12 yang mengintegrasikan tiga indikator utama: volatilitas harga (CV), pola perubahan harga jangka panjang (trend), dan potensi kejadian harga ekstrem (skewness).

Tabel 9 menyajikan hasil klasifikasi risiko berdasarkan nilai rata-rata Coefficient of Variation (CV) sebagai indikator utama volatilitas harga pada masing-masing cluster. Cluster 0 menunjukkan nilai CV sebesar 0.0981, yang mengindikasikan tingkat fluktuasi harga relatif lebih rendah dibandingkan Cluster 1 dengan nilai CV sebesar 0.1314. Perbedaan CV sebesar 0.0333 atau sekitar 33.9% menunjukkan bahwa provinsi-provinsi di Cluster 1 mengalami volatilitas harga yang signifikan lebih tinggi, sehingga lebih rentan terhadap gangguan stabilitas pasokan pangan. Berdasarkan hasil ini, Cluster 0 diklasifikasikan sebagai kelompok dengan *risiko rendah*, sedangkan Cluster 1 diklasifikasikan sebagai kelompok dengan *risiko tinggi* terhadap krisis pangan.

TABEL 9: KLASIFIKASI RISIKO BERDASARKAN KARAKTERISTIK CLUSTER

Cluster	CV Rata-rata	Tingkat Risiko
Cluster 0	0.0981	Risiko Rendah
Cluster 1	0.1314	Risiko Tinggi

Sementara itu, pada Gambar 6 ditunjukkan sebaran distribusi provinsi berdasarkan cluster risiko pangan. Mayoritas provinsi di Pulau Jawa mendominasi cluster dengan risiko krisis pangan tinggi yang disebabkan oleh volatilitas harga yang tinggi. Volatilitas ini mengakibatkan ketidakstabilan harga yang merepresentasikan ketidaktersediaan pasokan barang secara konsisten. Di sisi lain, provinsi-provinsi di Pulau Kalimantan, sebagian kecil Pulau Sulawesi, dan provinsi-provinsi di kawasan timur Indonesia memiliki risiko pangan yang lebih rendah.



Gambar 6: Peta distribusi geografis cluster risiko pangan

E. Pembahasan

1) *Interpretasi Pola Geografis Cluster:* Hasil clustering menunjukkan adanya pola geografis yang jelas dalam distribusi risiko volatilitas harga pangan antarprovinsi. Sebanyak 22 dari 34 provinsi (65%) tergolong dalam Cluster 1 dengan tingkat volatilitas harga relatif tinggi ($CV = 0.1314$), sementara 12 provinsi (35%) berada pada Cluster 0 dengan volatilitas lebih rendah ($CV = 0.0981$). Secara spasial, seluruh provinsi di Pulau Jawa secara konsisten tergolong dalam Cluster 1, sedangkan seluruh provinsi di Kalimantan berada pada Cluster 0. Pola ini mengindikasikan adanya faktor geografis dan struktural yang sistematis dalam membentuk dinamika volatilitas harga pangan antarwilayah.

Dominasi Pulau Jawa dalam Cluster 1 sejalan dengan temuan empiris sebelumnya yang mengidentifikasi Jawa sebagai pusat transmisi volatilitas harga pangan nasional [2]. Penelitian tersebut menunjukkan adanya keterkaitan volatilitas yang kuat dari Jawa ke wilayah lain, termasuk Sumatra, Kalimantan, dan Papua. Dalam konteks ini, volatilitas harga yang lebih tinggi di Jawa tidak hanya merefleksikan ketidakstabilan lokal, tetapi juga peran Jawa sebagai pusat pembentukan harga dalam sistem pangan nasional.

Perbedaan karakteristik antara Jawa dan Kalimantan dapat dipahami melalui tingkat integrasi pasar yang berbeda. Studi Bank Dunia [11] menunjukkan bahwa pasar pangan di Jawa memiliki tingkat integrasi spasial yang jauh lebih tinggi dibandingkan wilayah di luar Jawa. Integrasi pasar yang kuat memungkinkan transmisi harga yang cepat antarwilayah, sehingga guncangan harga di satu lokasi dapat segera menyebar ke wilayah lain. Mekanisme ini berkontribusi terhadap volatilitas agregat yang lebih tinggi pada wilayah yang terintegrasi secara kuat.

Sebaliknya, pasar pangan di Kalimantan dan wilayah timur Indonesia cenderung memiliki tingkat integrasi yang lebih lemah, sehingga transmisi harga antarwilayah berlangsung lebih lambat. Keterbatasan ini menyebabkan guncangan harga bersifat lebih terlokalisasi dan tidak segera menyebar, yang pada agregat wilayah tercermin sebagai volatilitas yang relatif lebih rendah. Namun, kondisi tersebut juga mengindikasikan adanya keterbatasan mekanisme penyeimbang harga lintas wilayah.

Peran infrastruktur transportasi dalam membentuk pola volatilitas harga pangan bersifat kontekstual. Penelitian sebelumnya menunjukkan bahwa konektivitas jalan yang baik dapat menurunkan volatilitas harga melalui peningkatan efisiensi distribusi [10]. Namun, dalam konteks wilayah dengan tingkat integrasi pasar yang sudah tinggi seperti Jawa, konektivitas yang kuat justru mempercepat penyebaran guncangan harga, sehingga berpotensi meningkatkan volatilitas agregat. Sebaliknya, keterbatasan infrastruktur di wilayah seperti Kalimantan dapat berfungsi sebagai penghambat transmisi volatilitas antarwilayah, meskipun dengan konsekuensi berupa tingkat harga rata-rata yang lebih tinggi.

Temuan ini mengungkap adanya paradoks stabilitas pada wilayah dengan tingkat integrasi pasar rendah. Provinsi-provinsi dalam Cluster 0 menunjukkan volatilitas harga yang lebih stabil bukan karena sistem pangan yang lebih tangguh, melainkan akibat keterisolasian spasial yang membatasi transmisi guncangan eksternal. Di satu sisi, kondisi ini melindungi wilayah tersebut dari volatilitas nasional; di sisi lain, keterbatasan integrasi meningkatkan kerentanan terhadap guncangan pasokan lokal yang sulit segera diimbangi melalui mekanisme perdagangan antarwilayah.

Dengan demikian, hasil clustering tidak hanya merefleksikan perbedaan tingkat volatilitas harga antarwilayah, tetapi juga mengungkap struktur spasial sistem pangan Indonesia yang bersifat terfragmentasi. Wilayah dengan integrasi pasar tinggi menghadapi risiko volatilitas sistemik, sementara wilayah dengan integrasi rendah cenderung mengalami stabilitas relatif

dengan kerentanan terhadap guncangan lokal.

2) *Komparasi dengan Penelitian Sebelumnya:* Penelitian sebelumnya yang menerapkan *Dynamic Time Warping* (DTW) untuk clustering harga beras antar provinsi di Indonesia [4] mengelompokkan wilayah berdasarkan kemiripan pola temporal deret waktu harga. Pendekatan DTW menekankan kesamaan bentuk pergerakan harga dari waktu ke waktu, sehingga provinsi dengan pola fluktuasi serupa dapat berada dalam satu cluster meskipun memiliki tingkat volatilitas yang berbeda.

Sebaliknya, penelitian ini mengadopsi pendekatan *feature-based clustering* dengan mengekstraksi karakteristik statistik dan temporal harga sebagai dasar pengelompokan. Perbedaan pendekatan ini menghasilkan fokus analisis yang berbeda: DTW menjawab pertanyaan mengenai kesamaan pola harga, sementara clustering berbasis volatilitas dalam penelitian ini berfokus pada kesamaan tingkat risiko ketidakstabilan harga antarwilayah. Meskipun demikian, kedua pendekatan menunjukkan indikasi konsisten terhadap karakteristik unik beberapa wilayah, yang mengisyaratkan adanya dinamika harga yang khas baik dari sisi pola maupun volatilitas.

Studi sebelumnya mengenai clustering ketahanan pangan di Indonesia [5] umumnya menggunakan indikator struktural berbasis data BPS—seperti aspek ketersediaan, akses, dan pemanfaatan pangan—serta mengevaluasi baik pendekatan hard clustering (K-Means, K-Medoids) maupun soft clustering (Fuzzy C-Means). Meskipun pendekatan soft clustering turut dianalisis, hasil evaluasi menunjukkan bahwa metode K-Means menghasilkan struktur cluster paling optimal, sehingga wilayah diklasifikasikan secara tegas ke dalam kategori rawan dan tidak rawan pangan..

Penelitian ini berbeda dari studi sebelumnya baik dari sisi data maupun metode yang digunakan. Data *time series* harga komoditas dimanfaatkan untuk menangkap dinamika dan volatilitas harga pangan, sehingga analisis risiko ketidakstabilan pangan menjadi lebih relevan. Selain itu, metode Fuzzy C-Means digunakan untuk mengakomodasi ketidakpastian dalam pengelompokan wilayah, di mana suatu wilayah tidak harus sepenuhnya berada dalam satu cluster tertentu. Pendekatan ini sesuai dengan karakteristik volatilitas harga, karena perbedaan antara kondisi stabil dan tidak stabil bersifat bertahap, sehingga memungkinkan beberapa wilayah berada pada posisi peralihan antar kelompok risiko.

Sementara itu hasil clustering dalam penelitian ini menunjukkan konsistensi konseptual dengan studi mengenai *price spillover effect* di Indonesia [2], yang mengidentifikasi Pulau Jawa sebagai pusat transmisi volatilitas harga pangan ke wilayah lain. Pola spasial cluster yang dihasilkan memperlihatkan konsentrasi wilayah berisiko tinggi pada kawasan yang secara ekonomi dan logistik terintegrasi kuat dengan Jawa.

Namun, penelitian ini melengkapi analisis spillover dengan menyediakan pemetaan heterogenitas risiko antarwilayah berdasarkan karakteristik volatilitas harga. Dengan demikian, analisis spillover menjelaskan mekanisme transmisi volatilitas, sementara pendekatan clustering berbasis fitur dalam penelitian ini mengidentifikasi variasi tingkat paparan dan respons wilayah terhadap guncangan harga tersebut.

3) *Keterbatasan Penelitian:* Penelitian ini memiliki beberapa keterbatasan yang perlu diperhatikan dalam interpretasi hasil. Pertama, analisis clustering dilakukan berdasarkan karakteristik statistik deret waktu harga komoditas tanpa mempertimbangkan faktor struktural seperti produksi, distribusi, dan kondisi sosial ekonomi, sehingga hasil pengelompokan lebih merefleksikan risiko ketidakstabilan harga daripada ketahanan pangan secara komprehensif. Kedua, pendekatan clustering bersifat statis terhadap periode pengamatan, sehingga dinamika perubahan klaster antarwaktu belum dianalisis secara eksplisit. Selain itu, analisis spillover difokuskan pada hubungan antarwilayah utama, sehingga potensi pengaruh dari faktor eksternal seperti kebijakan pemerintah atau gangguan global belum sepenuhnya tercakup.

IV. KESIMPULAN

Penelitian ini mengkaji pengelompokan risiko ketidakstabilan pangan di Indonesia dengan memanfaatkan deret waktu harga komoditas sebagai dasar analisis, sehingga mampu menangkap dinamika dan volatilitas harga antarwilayah. Melalui pendekatan *feature-based clustering* yang mengekstraksi karakteristik statistik utama data *time series*, penelitian ini memberikan perspektif alternatif terhadap studi ketahanan pangan yang umumnya berbasis indikator struktural. Penerapan metode Fuzzy C-Means memungkinkan representasi ketidakpastian dan zona transisi antarwilayah, di mana beberapa provinsi tidak diklasifikasikan secara tegas ke dalam satu kelompok risiko, melainkan memiliki tingkat keanggotaan pada lebih dari satu klaster.

Hasil clustering menunjukkan adanya heterogenitas risiko ketidakstabilan harga antarwilayah yang konsisten dengan pola spasial dan ekonomi Indonesia, serta diperkuat oleh temuan analisis spillover harga yang mengindikasikan peran wilayah tertentu sebagai pusat transmisi volatilitas. Temuan ini menegaskan bahwa analisis berbasis volatilitas harga dapat melengkapi pendekatan ketahanan pangan konvensional, khususnya dalam mengidentifikasi wilayah dengan risiko laten yang bersifat gradual dan dinamis, sehingga relevan sebagai dasar pertimbangan dalam perumusan kebijakan stabilisasi harga dan mitigasi risiko pangan.

- [1] FAO, "Food Security," *FAO Policy Brief*, no. 2, Rome, 2006.
- [2] A. Theresia, M. Ikhsan, F. N. Kacaribu, et al., "Spillover Effect of Food Producer Price Volatility in Indonesia," *Economies*, vol. 13, no. 9, p. 256, 2025.
- [3] C. J. Anwar, I. Suhendra, A. Srimulyani, V. M. Zahara, R. A. F. Ginanjar, and S. C. Suci, "Food Price and Inflation Volatilities during Covid-19 Period: Empirical Study of a Region in Indonesia," *WSEAS Transactions on Business and Economics*, vol. 20, pp. 1839–1848, 2023, doi:10.37394/23207.2023.20.161.
- [4] A. H. Rizaldi, I. M. D. Utama, and R. Andriani, "Implementation of Time Series Clustering with DTW to Clustering and Forecasting Rice Prices Each Provinces in Indonesia," *INFERENSI: Jurnal Statistika dan Aplikasinya*, vol. 9, no. 1, pp. 1–12, 2025.
- [5] W. W. Prastanika and A. W. Wijayanto, "Analisis Hard dan Soft Clustering Untuk Pengelompokan Indikator Ketahanan Pangan Indonesia 2021," *JUSTIN (Jurnal Sistem dan Teknologi Informasi)*, vol. 11, no. 4, pp. 596–604, Oct. 2023, doi:10.26418/justin.v11i4.68400.
- [6] A. López-Oriona, J. A. Vilar, and P. D'Urso, "Quantile-based fuzzy clustering of multivariate time series in the frequency domain," *Fuzzy Sets and Systems*, preprint, arXiv:2109.03728, 2021.
- [7] Poppe, M., Veerkamp, R.F., van Pelt, M.L., & Mulder, H.A. (2020). Exploration of variance, autocorrelation, and skewness of deviations from lactation curves as resilience indicators for breeding. *Journal of Dairy Science*, 103(2), 1667–1684. <https://doi.org/10.3168/jds.2019-17290>
- [8] Datavidia, "Indonesia Commodity Price," Kaggle, 2025. [Online]. Tersedia: <https://www.kaggle.com/datasets/datavidia/indonesia-commodity-price/data>. [Diakses: Des. 2025].
- [9] S. Askari, "Fuzzy C-Means clustering algorithm for data with unequal cluster sizes and contaminated with noise and outliers: Review and development," *Expert Systems with Applications*, vol. 165, p. 113856, 2021.
- [10] Lambert, L. H., Schoeneman Jr., J. P., Lambert, D. M., and Brienens, M. W. (2025). Road networks and food price volatility. *Global Food Security*, 47, 100884. <https://doi.org/10.1016/j.gfs.2025.100884>
- [11] M. Haile, J. J. Nijhoff, and S. Jaffee, "Food market integration and price differential across provinces in Indonesia," World Bank Group, Washington, DC, Tech. Rep., March 2019. [Online]. Available: <https://documents.worldbank.org/en/publication/documents-reports/documentdetail>